

(1) 生成資料

本系統的資料生成分為兩組獨立但可串接的模組，分別模擬「時間序列上的醫療行為」與「特定情境下的消費決策」。

第一組：臨床時序軌跡生成

- 1. 格式定義
 - 屬於縱向時間序列資料。
 - 以個別病患為追蹤主體，記錄隨時間推移的事件節點。
 - 核心內容包含：病患基本特徵（年齡、疾病種類）、每一次的看診天數、實際領藥天數、當次開立的藥物清單，以及該次給藥的涵蓋天數。
 - 這些資料後續會透過「滑動時間窗」的技術，轉換成利用過去一段時間的歷史紀錄，來預測下一次行為的標準機器學習格式。
- 2. 物理意義
 - 領藥延遲模擬：使用 Poisson 分配來模擬病患在真實世界中，可能因為忘記、沒空或保險審核等現實因素，導致「處方藥吃完的那天」與「實際回診領藥的那天」之間產生的時間落差。
 - 病程惡化模擬：設定特定的推進機率，讓病患隨著時間推移，可能從初期的單一用藥（例如只吃一種降血糖藥），逐漸惡化並推進到多重用藥階段（例如同時吃藥並施打胰島素）。
- 3. 目標
 - 生成具備強烈時間前後相依性的軌跡資料，讓時序模型能夠學習並捕捉病患的回診頻率、用藥習慣，以及處方演進的規律。

第二組：零售情境購物籃生成

- 1. 格式定義
 - 屬於橫斷面資料。
 - 以「單次交易」或「獨立購物籃」為單位。
 - 核心內容包含：病患當下的靜態特徵（當前年齡、確診疾病種類），以及多項零售商品（例如保健食品、化妝品、保險套等）是否購買的二元化標籤（買或不買）。
- 2. 物理意義
 - 生命週期曲線：依據年齡套用不同的基礎購買機率分佈。例如：衰退型（零食、化妝品隨年紀增長而購買率下降）、成長型（成人紙尿褲、保健品隨年紀增長而上升）、鐘型曲線（咖啡、助眠品在中壯年時期達到高峰）。
 - 衛教邏輯權重：疊加疾病種類對消費行為造成的改變。例如：高血壓患者會減少購買咖啡、增加購買助眠品；糖尿病患者則會大幅提升傷口包紮品（防範糖尿病引發的足部傷口）與無糖奶粉的購買率。
- 3. 目標
 - 大量生成無時間干擾的獨立樣本，專供擴散模型或神經網路學習「健康特徵」與「潛在消費意圖」之間高度複雜的非線性關係。

(2) 模型

系統最終採用了兩組核心預測模型，分別處理「臨床行為序列」與「零售商業推薦」。


第一組：臨床醫療序列模型

- 1. 輸入
 - 病患過去幾次領藥的歷史特徵，包含：轉換為多重標籤編碼的用藥清單、經過縮放處理的給藥天數，以及每次領藥之間的間隔天數。
 - 靜態特徵：數值化的年齡，以及經過「向量嵌入技術」轉換降維後的疾病類別特徵。
- 2. 架構
 - 主幹網路：使用「長短期記憶網路」來處理長度不固定的歷史時間序列，學習病患的回診規律。
 - 雙分支預測：將網路最後輸出的隱藏狀態與疾病特徵拼接後，分流到兩個網路計算頭：「用藥分類頭」與「天數迴歸頭」。
 - 醫學邏輯遮罩：在分類頭準備輸出預測機率時，強制套用預先定義的規則遮罩矩陣。透過數學運算，將「不屬於該確診疾病的藥物」預測機率直接降為負無窮大，確保模型絕對不會產生違反真實醫學倫理的預測。
- 3. 輸出
 - 時間預測：預測距離下一次領藥的間隔天數（透過平滑正值激勵函數，確保輸出結果永遠為正實數）。
 - 用藥預測：預測下一次回診時將領取的藥物清單（輸出各項藥品獨立的預測機率）。

第二組：零售推薦模型

- 1. 輸入
 - 病患的人口統計特徵（數值化年齡）。
 - 健康特徵（疾病類別編碼）。
 - 病患「目前正在使用」或「系統剛預測出即將領取」的藥物多重標籤編碼。
- 2. 架構
 - 本組同時訓練了兩種網路來進行整合：
 - 主力條件擴散模型：將原先用於生成影像的技術應用於表格資料上。核心為條件去噪多層感知機，將年齡與疾病作為情境脈絡，在多步驟的去噪過程中引導模型，從純高斯雜訊中逐步還原出符合該病患特徵的購物籃機率分佈。
 - 輔助一般神經網路：使用標準的全連接層，直接從「年齡加上用藥特徵」映射到「零售商品」的購買機率，作為對照與輔助。
- 3. 輸出

- 生成各類零售商品(如保健食品、成人奶粉等)的購買機率。系統會將擴散模型與輔助神經網路的預測機率進行平均, 接著依分數高低排序, 提取分數最高的前幾名作為最終的推薦名單。




圖一, 模型架構圖

(3) 系統

1. 流程


- 資料準備: 當載入原始軌跡資料後, 系統會自動進行特徵對齊、數值縮放, 並利用滑動時間窗的方法建立訓練集與測試集。
- 聯合訓練: 在同一個執行流程中, 系統會依序完成長短期記憶網路、輔助推薦神經網路, 以及條件擴散模型的訓練, 並自動生成特徵編碼器與醫學規則遮罩。
- 推論評估: 系統會在未看過的測試集上計算嚴格的成效指標, 包含評估購物籃完整度的「交併比相似度」、推薦命中率的「召回率」, 以及預測回診天數的「平均絕對誤差天數」。



圖二，介面資料處理

2. 整合

- 系統在進行未來預測時，採用了串聯式自我滾動推演機制：
 1. 首先呼叫「臨床模型」，給定病患當前的歷史紀錄，預測出「下次哪天會來」與「下次會拿什麼藥」。
 2. 接著，將這組「預測出來的藥物」與病患的基本特徵，無縫接軌地輸入至「零售模型」中，生成該次未來造訪時最適用的「商品推薦清單」。
 3. 最後，將本次預測出的天數、用藥與商品，當作既定事實加入歷史紀錄中，繼續往下推演下一次的行為，直到超出使用者指定的未來預測天數為止。



圖三，模型分析與預測



圖四，使用者未來預測